



# 机器学习导论习题课

## 第二次作业



# 题目1: 多标记 Logistic 回归

在多标记任务中，每个示例都有一个标记集合  $\mathbf{y} = \{y_1, y_2, \dots, y_l\}$  并且标记满足  $y_i \in \{0, 1\}$ 。假设后验概率满足条件独立性：

$$P(\mathbf{y}|\mathbf{x}) = \prod_{i=1}^l P(y_i|\mathbf{x})$$

请使用 Logistic 回归方法解决一下问题。

(1) 请给出你的 Logistic 回归模型的对数似然函数；

(2) 请计算你对数似然函数的梯度。

# 题目1: 多标记Logistic回归

(1) 解：对于特定标记 $y_j$ , 其logistic回归模型的对数似然函数可以写成：

$$l(w, b) = \sum_{i=1}^m \ln P(y_j^i | x^i; w, b)$$

令 $\beta = (w; b)$ ,  $\hat{x} = (x; 1)$ 则,

$$P(y_j^i = 1 | x^i; w, b) = \frac{e^{y_j^i \beta_j^T \hat{x}^i}}{1 + e^{\beta_j^T \hat{x}^i}}$$

$$\ln P(y_j^i | x^i; w, b) = y_j^i \beta_j^T \hat{x}^i - \ln (1 + e^{\beta_j^T \hat{x}^i})$$

$$l(\beta) = \sum_{i=1}^m (y_j^i \beta_j^T \hat{x}^i - \ln (1 + e^{\beta_j^T \hat{x}^i}))$$

# 题目1: 多标记Logistic回归

由于后验概率满足条件独立性，所以：

$$\ln P(y|x) = \sum_{j=1}^l \ln P(y_j|x)$$
$$l(\beta) = \sum_{j=1}^l \sum_{i=1}^m (y_j^i \beta_j^T \hat{x}^i - \ln(1 + e^{\beta_j^T \hat{x}^i}))$$

(2) 答：梯度为

$$\frac{\partial l(\beta)}{\partial \beta_j} = \sum_{i=1}^m (y_j^i \hat{x}^i - \frac{\hat{x}^i e^{\beta_j^T \hat{x}^i}}{1 + e^{\beta_j^T \hat{x}^i}}) = \sum_{i=1}^m (y_j^i \hat{x}^i - \hat{x}^i P(y_j^i = 1|x^i; w, b))$$
$$\nabla_{\beta}.l(w, b) = [\frac{\partial l(w, b)}{\partial \beta_1}, \dots, \frac{\partial l(w, b)}{\partial \beta_l}]$$

这道题目比较简单。同学们最大问题是上下标标注很不准确，经常会丢掉*i*或者*j*。

# 题目1: 多标记Logistic回归

第(2)问的本意只是让大家求到每个标记的梯度就可以了，不过也有人求解了每个标记在所有纬度的梯度，这个答案也被接受。

$$\begin{aligned} l(\beta) &= \sum_{j=1}^l \sum_{i=1}^m (y_j^i \beta_j^T \hat{x}^i - \ln(1 + e^{\beta_j^T \hat{x}^i})) \\ &= \sum_{j=1}^l \sum_{i=1}^m (y_j^i \sum_{t=1}^d \beta_{jt} \hat{x}_t^i - \ln(1 + e^{\sum_{t=1}^d \beta_{jt} \hat{x}_t^i})) \end{aligned}$$

$$\frac{\partial l(\beta)}{\partial \beta_{jt}} = \sum_{i=1}^m (y_j^i \hat{x}_t^i - \frac{\hat{x}_t^i \exp\{\sum_{t=1}^d \beta_{jt} \hat{x}_t^i\}}{1 + \exp\{\sum_{t=1}^d \beta_{jt} \hat{x}_t^i\}}) = \sum_{i=1}^m (y_j^i \hat{x}_t^i - \hat{x}_t^i P(y_j^i = 1 | x^i; w, b))$$

# 题目1: 多标记 Logistic 回归

---

所以梯度为一个  $l \times d$  的矩阵，其第  $(j, t)$  个元素为：

$$[\nabla_{\beta} l(w, b)]_{jt} = \frac{\partial l(\beta)}{\partial \beta_{jt}}$$

请注意这个梯度不是一个二阶梯度，而是对一个矩阵变量的一阶梯度，这个梯度的求解更加复杂，而且涉及的参数和符号更多，也就意味着更多的错误。

非常不幸，助教没有发现一个同学算对了这个矩阵梯度，所以计算这个梯度的同学分数可能会更低。

## 题目2: 线性判别分析

---

证明对线性回归后得到的 $\hat{Y}$ 做LDA和对原始空间 $X$ 做LDA结果是等价的。

证明：原始空间下的类内散度矩阵为： $S_w = \sum_{x \in X_i} (x - u_i)(x - u_i)^T$ ， $u_i$ 为第 $i$ 个类的类中心。 $X_i$ 表示第 $i$ 个类的所有样本。类间散度矩阵为： $S_b = \sum_{i=1}^N m_i (u_i - u)(u_i - u)^T$ ， $m_i$ 表示第 $i$ 个类的样本个数， $u$ 是类中心的中心。

变换后的空间下，

$$S_w^y = \sum_{y \in \hat{Y}_i} (y - u_i^y)(y - u_i^y)^T = \sum_{x \in X_i} B^T (x - u_i)(x - u_i)^T B = B^T S_w B$$

$$S_b^y = \sum_{i=1}^N m_i (u_i^y - u^y)(u_i^y - u^y)^T = \sum_{i=1}^N m_i (B^T u_i - B^T u)(B^T u_i - B^T u)^T = B^T S_b B$$

## 题目2: 线性判别分析(2)

---

原始空间下的目标式为:  $S_b W = \lambda S_w W$

新空间下的目标公式为:  $B^T S_b B W^y = \lambda^y B^T S_w B W^y$

可令:  $B W^y = W$

则, 对 $\hat{Y}$ 做投影变换可得:  $\hat{Y} W^y = (XB)(B^{-1}W) = XW$ 。

所以,  $\hat{Y}$ 上的LDA和 $X$ 上的LDA等价。



# 题目3:编程题

---

题目要求:

1. 实现LR算法, 优化算法可选择梯度下降, 亦可选择牛顿法
2. 利用“一对多”(One vs. Rest, OvR)策略对分类LR算法进行改进, 处理多分类任务

# 题目3:编程题

---

一般实验报告需要从 **方法-实现-实验结果** 三方面来写，在方法中需要简要介绍方法的思路，过程，给出伪代码

在实现中，需要结合方法给出算法实现的模块划分，显示出自己代码实现的条理性。

实验结果中，给出题目中要求的实验结果只能说达到了基本要求，方法只有通过对比才能展示其有效性，所以大家要给出实验的对比效果。参数调查也是一项比较重要的内容，如优化方法中的超参设置等。

鼓励大家对实验提出自己的感想或者改进思路。

# Effect of Learning Rate

例子


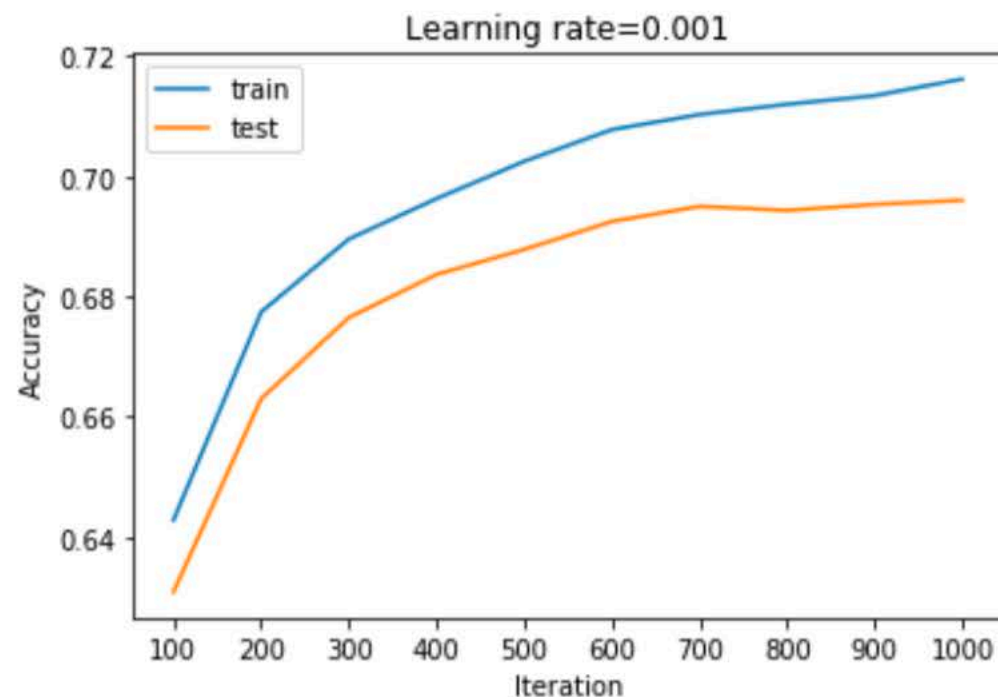


表 3: 相关函数参数及功能

函数名	参数	功能
sigmod	inX	计算inX对应Sigmoid函数的y值
gradAscent	dataMatIn、 classLabels、alpha、 maxCycle	对训练数据集dataMatIn和classLabels，设定步长为alpha，迭代次数为maxCycle，用梯度下降法返回对应的 $w$
classifyVector	inX, weights	对每个样本inX，用weights算出对应的预测结果
classifyAll	dataSet, weights	对数据集inX，用weights算出对应的预测结果
Normalize	dataSet	对数据集dataSet进行归一化
getTrainDataSet	无	获得训练数据集
getTestDataSet	无	获得测试数据集
clearResult	trainShares, classNum	将标签trainShares中classNum类的设为0，其他的设为0
Classfy	testDataSet, weights	对测试数据集testDataSet利用26个分类器的weights求得最终的分类预测结果
main	无	开始运行

## 参考文献

- [1] Jerome H. Friedman, Robert Tibshirani, Trevor Hastie. The Elements of Statistical Learning. Chapter 4: 106-112.
- [2] 统计学习 [The Elements of Statistical Learning] 第四章习题 <https://wenku.baidu.com/view/0a8fc43043323968011c927f.html>
- [3] 机器学习-Logistic 回归计算过程的推导 [https://blog.csdn.net/ligang\\_csdn/article/details/53838743](https://blog.csdn.net/ligang_csdn/article/details/53838743)

参考文献的作用：1. 充分尊重前人工作；2. 体现工作量